

# Анализ Foxd3 ChIP-seq на четырёх стадиях развития нервного гребня *Danio rerio*

Домашнее задание к семинару 2 (ChIP-seq)

## 1. Цель и данные

Цель — повторить семинарский анализ Foxd3 biotin-ChIP-seq для 14 ss, выполнить тот же анализ для 75% epiboly и 1–2 ss и сравнить все четыре стадии (75ep → 1–2ss → 5–6ss → 14ss). Данные — GSE106676, paired-end BAM, выровненные на GRCz11 и отфильтрованные до ядерных хромосом. Для 5–6 ss использованы готовые файлы из `teacher_example/5-6ss/`. Хромосомы в геноме названы RefSeq-аксессуями (NC\_007112.7 = chr1 ... NC\_007117.7 = chr6, NC\_007126.7 = chr15), NW\_\* — неразмещённые скаффолды.

## 2. Форматы файлов

| Формат     | Что хранит                                                                                    | Тип    | Для чего использовали            |
|------------|-----------------------------------------------------------------------------------------------|--------|----------------------------------|
| FASTA      | последовательность хромосом генома (+ индекс .fai с длинами)                                  | text   | референс GRCz11, chrom.sizes     |
| GTF        | аннотация генов: тип элемента (gene/exon/CDS), координаты, strand, gene_id/gene_name          | text   | гены в IGV                       |
| BAM        | выравнивания ридов: позиция, MAPQ, CIGAR, флаги, координата мейта                             | binary | исходные ChIP и Input            |
| BAI        | индекс BAM для быстрого доступа к региону                                                     | binary | samtools -L, deepTools, IGV      |
| BigWig     | непрерывный сигнал вдоль генома (значение в бинах), индексированный                           | binary | CPM ChIP/Input, log2(ChIP/Input) |
| BED        | геномные интервалы chrom, start (0-based), end, [name, score, strand]                         | text   | summits, пересечения пиков       |
| narrowPeak | BED6+4: пик + signalValue (fold enrichment), $-\log_{10} p$ , $-\log_{10} q$ , позиция summit | text   | основной результат MACS3         |
| peaks.xls  | текстовая таблица MACS3 (не Excel): параметры запуска (d, число фрагментов) и пики            | text   | глубина и размер фрагмента       |
| TSV        | таблица с табуляцией                                                                          | text   | FRiP, сводные таблицы            |
| matrix.gz  | матрица deepTools «пики × бины» ( $\pm 2$ kb вокруг summit по 20 bp) для каждого BigWig       | gzip   | plotHeatmap, plotProfile         |
| PDF        | готовые графики                                                                               | binary | heatmap, профили                 |

BAM → BigWig → narrowPeak: сначала отдельные выравнивания, затем непрерывное нормированное покрытие, затем дискретные участки, где сигнал ChIP статистически выше Input.

## 3. Методы

Для каждой стадии (14ss, 75ep, 1–2ss) выполнено: `samtools flagstat` → `bamCoverage` (CPM, бин 10 bp) для ChIP и Input → `bigwigCompare` ( $\log_2$ , pseudocount 1) → `macs3 callpeak` (BAMPE,  $g = 1,36 \cdot 10^9$ ,  $q = 0,01$ ) → FRiP (`samtools view -c -L` / `samtools view -c`) → `computeMatrix` ( $\pm 2$  kb вокруг summit) → `plotHeatmap`, `plotProfile`. Стадии сравнивались через `bedtools intersect` (-u/-v) и `bedtools jaccard`. Кроме того, все пики объединены (`bedtools merge`, 982 региона), и по ним построен  $\log_2(\text{ChIP}/\text{Input})$  всех стадий. Команды — в приложении.

#### 4. Семинар: 14 ss

flagstat показывает число выравниваний по категориям FLAG: primary/secondary, дубликаты, mapped, properly paired и т.д. Во всех BAM 100% mapped и properly paired, secondary и синглтонов нет, то есть файлы уже отфильтрованы. В ChIP 14ss 41,6 млн выравниваний, в Input — 27,8 млн.

MACS3 нашёл **170 пиков**. Это не число сайтов связывания Foxd3: число пиков зависит от порога, глубины и качества IP. Слабые сайты под порог не попадают, часть пиков ложные (52 пика лежат на скаффолдах NW\_\*), а ChIP не отличает прямое связывание от непрямого. Сортировка `sort -k9,9nr` идёт по 9-й колонке,  $-\log_{10}(q)$ . Самый значимый пик:

|             |          |          |                    |      |   |         |        |         |     |
|-------------|----------|----------|--------------------|------|---|---------|--------|---------|-----|
| NC_007126.7 | 35583506 | 35583991 | foxd3_14ss_peak_74 | 3214 | . | 24.9995 | 330.35 | 321.453 | 230 |
|-------------|----------|----------|--------------------|------|---|---------|--------|---------|-----|

signalValue = 25 (fold enrichment),  $-\log_{10} p = 330,4$ ,  $-\log_{10} q = 321,5$ , то есть  $q = 10^{-321,45} \approx 3,5 \cdot 10^{-322}$ , summit = 35 583 736. FRiP = 67 346 / 41 553 880 = **0,16%**. Из 839 пиков 5–6ss с 14ss пересекаются 40, специфичных для 14ss пиков — 130.





Рис. 1. 14 ss, средний профиль  $\pm 2$  kb вокруг summit.



**Рис. 2. 14 ss, heatmap вокруг summit (170 пиков).**

computeMatrix даёт матрицу, где строки — пики, а столбцы — 200 бинов по 20 bp от -2 до +2 kb; значения — CPM для ChIP и Input. plotHeatmap рисует каждую строку отдельно, а plotProfile усредняет по всем пикам.

У ChIP узкий пик ровно в summit, у Input сигнал ровный. Значит, найденные пики — реальное локальное обогащение, а не особенности фона. Сильный сигнал у 14ss есть только в небольшой части пиков (верх heatmap), у остальных обогащение слабое.

## 5. Домашнее задание: 75% epiboly и 1–2 ss

|                               | 75% epiboly                   | 1–2 ss                        |
|-------------------------------|-------------------------------|-------------------------------|
| ChIP / Input выравнивания     | 23 863 894 / 39 931 858       | 12 816 614 / 33 460 348       |
| Пиков                         | 36                            | 40                            |
| Самый значимый пик            | NC_007113.7:33276014-33276551 | NC_007113.7:33276062-33276596 |
| signalValue                   | 21,70                         | 21,23                         |
| $-\log_{10} p / -\log_{10} q$ | 109,26 / 100,05               | 65,27 / 56,18                 |
| q-value                       | $8,9 \cdot 10^{-101}$         | $6,6 \cdot 10^{-57}$          |
| FRiP                          | 4 101 / 23 863 894 = 0,017%   | 1 799 / 12 816 614 = 0,014%   |

На обеих стадиях самый значимый пик находится в одном и том же месте (chr2:33,276 Mb), и следующие пики тоже в основном общие. Пиков мало, FRiP очень низкий, но средние профили показывают чёткий пик ChIP в summit при ровном Input. У 75ep в нескольких верхних строках heatmap сигнал высокий и в Input, то есть часть пиков лежит в областях с повышенным фоном.




Рис. 3. 75% epiboly, средний профиль.




Рис. 4. 1–2 ss, средний профиль.




Рис. 5. Heatmap вокруг summit: слева 75% еріболу (36 пиков), справа 1–2 ss (40 пиков).

## 6. Сравнение четырёх стадий

| Стадия | ChIP выравн. | Input выравн. | Пиков | FRiP   | max $-\log_{10}(q)$ | медиана FE | пиков с FE $\geq 10$ |
|--------|--------------|---------------|-------|--------|---------------------|------------|----------------------|
| 75ep   | 23 863 894   | 39 931 858    | 36    | 0,017% | 100,1               | 5,8        | 6                    |
| 1–2ss  | 12 816 614   | 33 460 348    | 40    | 0,014% | 56,2                | 6,1        | 3                    |
| 5–6ss  | 18 853 396   | 57 051 062    | 839   | 0,236% | 163,7               | 5,5        | 54                   |
| 14ss   | 41 553 880   | 27 794 668    | 170   | 0,162% | 321,5               | 3,3        | 5                    |

Больше всего пиков на 5–6 ss, и обогащение там тоже самое сильное: наибольший FRiP и больше всего пиков с FE  $\geq 10$ . На объединённом наборе из 982 регионов медианный max  $\log_2(\text{ChIP}/\text{Input})$  составляет 1,39 для 5–6ss против 0,20–0,39 для остальных стадий (рис. 6). Максимальный  $-\log_{10}(q)$  у 14ss связан не с силой связывания, а с глубиной: у 14ss самая большая ChIP-библиотека и самый низкий медианный FE.

Разницу в числе пиков нельзя объяснить только биологией. На неё влияют:

- глубина ChIP: у 1–2ss всего 6,4 млн фрагментов;
- эффективность pull-down: FRiP 0,01–0,24% на всех стадиях, что намного ниже обычных для TF ~1%;
- доля foxd3<sup>+</sup> клеток в целом эмбрионе, особенно на 75ep;
- глубина Input;
- артефакты сборки: 31% пиков 14ss лежат на скаффолдах NW\_\*;
- то, что 5–6ss обработан отдельно.




Рис. 6.  $\log_2(\text{ChIP}/\text{Input})$  всех стадий на объединении всех пиков (982 региона), сортировка по 5–6ss.

7. Попарное сравнение пиков

| А     | В     | пиков А | пиков В | А пересек. В | В пересек. А | только А | только В | Jaccard |
|-------|-------|---------|---------|--------------|--------------|----------|----------|---------|
| 75ep  | 1–2ss | 36      | 40      | 12           | 12           | 24       | 28       | 0,174   |
| 75ep  | 5–6ss | 36      | 839     | 22           | 22           | 14       | 817      | 0,023   |
| 75ep  | 14ss  | 36      | 170     | 18           | 18           | 18       | 152      | 0,075   |
| 1–2ss | 5–6ss | 40      | 839     | 30           | 30           | 10       | 809      | 0,028   |
| 1–2ss | 14ss  | 40      | 170     | 12           | 12           | 28       | 158      | 0,043   |
| 5–6ss | 14ss  | 839     | 170     | 40           | 40           | 799      | 130      | 0,037   |




Рис. 7. Индекс Жаккара (слева) и доля пиков стадии-строки, пересекающихся с пиками стадии-столбца (справа).

Пиков, которых нет ни на одной другой стадии: 75ep — 6, 1–2ss — 7, 5–6ss — 773, 14ss — 119. На всех четырёх стадиях есть пики в 6 регионах.

1. Больше всего похожи 75ep и 1–2ss (Jaccard 0,174). Ранние пики к тому же в основном есть и на 5–6ss (61% и 75%); Jaccard с 5–6ss маленький только потому, что 5–6ss содержит гораздо больше пиков.
2. Сильнее всего различаются 5–6ss и 14ss: на 14ss есть только 5% пиков 5–6ss.
3. Признаки перестройки есть: от 5–6ss к 14ss большинство пиков пропадает и появляются новые. Но новые пики 14ss в основном слабые.
4. Если на стадии не вызван пик, это ещё не значит, что связывания нет. Пик — результат порога при данной глубине и качестве IP. На рис. 6 в регионах 5–6ss у остальных стадий виден слабый сигнал в центре, то есть связывание, скорее всего, есть, но ниже порога. Кроме того, intersect требует перекрытия интервалов, и сдвиг пика меняет результат.

8. IGV

Загружены ChIP CPM, Input CPM, log2(ChIP/Input), narrowPeak и GRCz11.gtf. Цвета: 75ер синий, 1–2ss фиолетовый, 5–6ss зелёный, 14ss бирюзовый, Input серый. Шкала CPM внутри скриншота одинаковая для всех стадий.



Рис. 8. Сильный пик 5–6 ss: NC\_007117.7:32,085,001-32,212,000 (chr6). Пик foxd3\_5-6ss\_chip\_peak\_211 (32,206,483-32,207,024, FE 21,  $-\log_{10} q$  163,7) — самый значимый на 5–6 ss. Он находится примерно в 113 kb от гена foxd3 (слева), что соответствует энхансеру enh6 из статьи. Input ровный,  $\log_2 \approx 3,5$ .




Рис. 9. Регион с пиком на всех стадиях: NC\_007113.7:33,273,278-33,279,277 (chr2), summit около 33,276,270.

Положение пика одинаковое на всех стадиях, но сила обогащения разная: max ChIP CPM 2,1 (75ep), 2,0 (1-2ss), 12,9 (5-6ss), 0,9 (14ss); max log2 1,5 / 1,4 / 3,3 / 0,7. Foxd3 связан здесь уже на гаструляции, а максимум сигнала приходится на 5-6ss.




Рис. 10. Stage-specific регион: NC\_007112.7:256,937-262,936 (chr1). Пик foxd3\_5-6ss\_chip\_peak\_1 (FE 21,  $-\log_{10} q$  63) есть только на 5–6ss, у 5'-конца гена *cenpe*; ChIP CPM 6,6 на 5–6ss и 0,5–0,9 на остальных стадиях.

Другой пример stage-biased региона — самый значимый пик 14ss (NC\_007126.7:35,583,736, интрон *mesom*). Пика нет на 75ep и 1–2ss, он появляется на 5–6ss, причём сигнал ChIP на 5–6ss втрое выше, чем на 14ss (9,8 против 3,2 CPM).

## 9. Интерпретация и вывод

1. Ландшафт связывания Foxd3 не постоянен. Сначала связано немного сайтов, к 5–6 ss их становится в разы больше, а к 14 ss набор снова сужается и частично меняется.
2. Самый выраженный сигнал на 5–6 ss (спецификация нервного гребня).
3. Стабильные участки — 6 регионов, связанных на всех стадиях, включая дистальный энхансер самого *foxd3*. Это самые сильные пики ранних стадий, что согласуется с ролью Foxd3 как пионер-фактора на ранних этапах.
4. Появляются сотни сайтов на 5–6 ss (например, *cenpe*), которые затем исчезают; часть сайтов появляется после 1–2 ss и сохраняется до 14 ss (*mesom*). Это качественно согласуется с выводом статьи о смене роли Foxd3 от активатора/piioneer к репрессору.
5. ChIP-seq показывает только, где белок связан. По нему нельзя понять, активирует связывание ген или подавляет: ближайший ген не обязательно мишень (энхансер *foxd3* находится в 113 kb от гена), и не видно состояния хроматина и изменения экспрессии.
6. Для проверки функции нужны данные статьи для control и *foxd3*-mutant:
  - ATAC-seq — открывается ли хроматин в пиках при наличии Foxd3;

- **H3K27ac ChIP-seq** — активны ли эти элементы как энхансеры;
- **RNA-seq** — меняется ли экспрессия соседних генов у мутанта.

**Итог.** От гаструляции к миграции нервного гребня связывание Foxd3 сначала ограничено небольшим набором сильных сайтов, на 5–6 ss резко расширяется, а к 14 ss сокращается и частично смещается к новым участкам. Биологическим можно считать:

- стабильное ядро сайтов, воспроизводящееся в четырёх независимых библиотеках;
- то, что ранние сайты входят в набор 5–6 ss;
- появление новых сайтов там, где на ранних стадиях нет даже слабого сигнала.

А вот точное число пиков, большинство «исчезнувших» сайтов и значительную часть новых пиков 14 ss нельзя отделить от различий в качестве ChIP: FRiP везде намного ниже 1%, глубина различается в 3 раза, реплик нет, у 14ss много слабых пиков на скаффолдах.

## Приложение. Команды

```
# s = 14ss, 75ep, 1-2ss
chip=data/$s/foxd3_${s}_chip.nuclear.bam; inp=data/$s/foxd3_${s}_input.nuclear.bam
samtools flagstat $chip; samtools flagstat $inp

bamCoverage -b $chip -o results/signal/foxd3_${s}_chip.CPM.bw --normalizeUsing CPM --binSize 10 --
numberOfProcessors 2
bamCoverage -b $inp -o results/signal/foxd3_${s}_input.CPM.bw --normalizeUsing CPM --binSize 10 --
numberOfProcessors 2
bigwigCompare -b1 results/signal/foxd3_${s}_chip.CPM.bw -b2 results/signal/foxd3_${s}_input.CPM.bw \
--operation log2 --pseudocount 1 --binSize 10 -o results/signal/foxd3_${s}.log2_IP_Input.bw

macs3 callpeak -t $chip -c $inp -f BAMPE -g 1360000000 -n fofd3_${s} -q 0.01 --outdir results/peaks
wc -l results/peaks/foxd3_${s}_peaks.narrowPeak
sort -k9,9nr results/peaks/foxd3_${s}_peaks.narrowPeak | head

samtools view -c $chip
samtools view -c -L results/peaks/foxd3_${s}_peaks.narrowPeak $chip # FRiP = второе / первое

computeMatrix reference-point --referencePoint center -R results/peaks/foxd3_${s}_summits.bed \
-S results/signal/foxd3_${s}_chip.CPM.bw results/signal/foxd3_${s}_input.CPM.bw \
-b 2000 -a 2000 --binSize 20 -o results/figures/foxd3_${s}.matrix.gz
plotHeatmap -m results/figures/foxd3_${s}.matrix.gz -out results/figures/foxd3_${s}.heatmap.pdf \
--samplesLabel "Fofd3 ChIP" "Input" --refPointLabel summit
plotProfile -m results/figures/foxd3_${s}.matrix.gz -out results/figures/foxd3_${s}.profile.pdf \
--samplesLabel "Fofd3 ChIP" "Input" --refPointLabel summit

# сравнение стадий (для каждой пары A, B)
bedtools intersect -a A.narrowPeak -b B.narrowPeak -u | wc -l
bedtools intersect -a A.narrowPeak -b B.narrowPeak -v | wc -l
bedtools jaccard -a A.sorted.bed -b B.sorted.bed
cat sorted/*.bed | cut -f1-3 | sort -k1,1 -k2,2n | bedtools merge -i - > union_peaks.bed
computeMatrix reference-point --referencePoint center -R union_peaks.bed \
-S fofd3_75ep.log2_IP_Input.bw fofd3_1-2ss.log2_IP_Input.bw fofd3_5-6ss_chip.log2_IP_Input.nuclear.bw
foxd3_14ss.log2_IP_Input.bw \
-b 2000 -a 2000 --binSize 20 --missingDataAsZero -o union_log2.matrix.gz
plotHeatmap -m union_log2.matrix.gz -out union_log2.heatmap.png --colorMap RdBu_r --zMin -2 --zMax 2 --
sortUsingSamples 3
```