

Домашнее задание: анализ ампликонов гена 16S рРНК в QIIME

2

Часть 1 — влияние загрязнения почвы керосином (*soil*, PRJNA786393). Часть 2 — данные семинара (*mice*).

Условия выполнения

Анализ выполнен на кластере calc.cod.phystech.edu. Все ресурсоёмкие шаги (импорт, DADA2, классификация, построение дерева, метрики разнообразия) запускались через SLURM на вычислительных узлах (раздел AMD9554), а не на login-узле. Отличия от текста задания:

- **Пути.** исходные данные лежат в /home/STUDY/FBMF/bioinformatics/metagenomes/{*soil_hw*, *mice*}, а не в /projects/...;
- **Версия QIIME 2.** QIIME 2 amplicon 2024.10 (как в задании) запускался из официального контейнера quay.io/qiime2/amplicon:2024.10 через Singularity: установить его через conda не удалось, потому что загрузки с packages.qiime2.org с кластера обрываются;
- **Манифесты.** файлы-манифесты содержали windows-переводы строк (CRLF), для импорта были сделаны копии без символов \r;
- **Параметры.** для *soil* использованы ровно параметры DADA2 и классификатор GreenGenes2 (2022.10.backbone.v4, sklearn 1.4.2) из задания.

Часть 1. Почва, загрязнённая керосином

36 образцов: 3 уровня загрязнения (*k0* — контроль, *k5* — 5 г/кг, *k25* — 25 г/кг) × 4 временные точки (*t1* = 3 сут, *t2* = 90 сут, *t3* = 180 сут, *t4* = 360 сут) × 3 повторности. Анализировались только прямые прочтения (*R1*).

Задача 1. FastQC для образца SRR17307316 (*k0*, *d3*, *r1*)

Показатель	Значение	Статус FastQC
Число прочтений	10 833	PASS
Длина прочтения	251 нт (все одинаковые)	PASS
GC-состав	57 %	PASS
Кодировка качества	Sanger / Illumina 1.9 (Phred+33)	—
Per base sequence quality	медиана Q ≥ 33 по всей длине	PASS
Per base sequence content	сильный перекося состава в начале	FAIL
Sequence duplication levels	очень высокая доля дубликатов	FAIL
Overrepresented sequences	есть	FAIL
Adapter content / N content	адаптеров и N нет	PASS




Рис. 1. Качество по позициям прочтения (SRR17307316, R1).

Качество прочтений высокое: медиана Q держится выше 33 на всей длине, к 3'-концу немного снижается (нижние «усы» опускаются до Q=20 только в последних позициях). Первые ~5 позиций имеют пониженное качество (Q≈33). Ошибки FastQC по составу нуклеотидов, дубликатам и сверхпредставленным последовательностям — это ожидаемая особенность ампликонных данных, а не брак:

- все прочтения начинаются с одного и того же праймера 515F (GTGCCAGCMGCCGCGGTAA), поэтому в первых позициях состав фиксирован;
- секвенируется один и тот же фрагмент гена 16S, поэтому одинаковых последовательностей много — дубликаты здесь отражают реальную численность таксонов.

Вывод: данные хорошего качества и пригодны для анализа; нужно отрезать праймер в начале и слабый 3'-конец.

Задача 2. Зачем нужен --p-trim-left 25

Прочтения R1 начинаются с последовательности праймера 515F (19 нт, например GTGCCAGCCGCGCGGTAA...). Праймер — это не биологическая последовательность образца: он навязан ПЦР, содержит вырожденную позицию (M) и одинаков у всех бактерий. Если его оставить, DADA2 может разделить одну бактерию на несколько ASV из-за вариантов праймера, а участок не несёт таксономической информации. Отрезая 25 нт, мы:

- удаляем праймер (19 нт) и несколько следующих за ним позиций;
- убираем начальные позиции с пониженным качеством (видно на рис. 1);
- получаем у всех прочтений одинаковую стартовую точку, что нужно для корректного сравнения ASV между образцами.

Задача 3. Статистика фильтрации DADA2

Показатель	Значение
Всего прочтений на входе	641 362
Осталось после всех этапов (non-chimeric)	608 362 (≈ 95 %)
Прошло фильтр по качеству (по образцам)	97,9 – 99,9 %

Осталось после удаления химер (по образцам)	89,4 – 97,1 %, в среднем 94,9 %
Самый большой образец	SRR17307475 (k0, d90) — 43 518 прочтений
Самый маленький образец	SRR17307380 (k0, d360) — 4 809 прочтений



Рис. 2. Число прочтений в образцах до и после DADA2 (серое — исходно, синее — осталось).

После всех этапов остаётся около 95 % исходных прочтений. Это говорит о хорошем качестве данных: фильтр по качеству почти ничего не отбрасывает, доля химер невелика (максимум $\approx 10\%$ в SRR17307273). Основная проблема — неравномерная глубина секвенирования: самый большой и самый маленький образцы различаются примерно в 9 раз. Поэтому для сравнения разнообразия нужно разрежение (rarefaction) до одинаковой глубины. Выбрано значение `--p-sampling-depth 4800`, чуть меньше минимального образца: так ни один образец не теряется.

Задача 4. Почему достаточно классификатора, обученного на V4

Праймеры 515F–907R амплифицируют участок V4–V5 (≈ 400 нт), но мы анализируем только прямые прочтения R1. R1 начинается с праймера 515F, то есть с начала V4, а после обрезки (`trim-left 25`, `trunc-len 200`) у нас остаётся фрагмент примерно со 540-й по 715-ю позицию гена 16S (нумерация *E. coli*). Он целиком лежит внутри участка V4, который амплифицирует пара 515F–806R и на котором обучен классификатор, и до V5 (≈ 820 – 880 нт) не доходит. Значит, в анализируемых последовательностях нет информации из V5, и классификатор, обученный на V4, покрывает ровно тот участок, который у нас есть. Naïve Bayes классификатор тем точнее, чем ближе обучающие последовательности к реально прочитанному фрагменту, поэтому V4-классификатор здесь даже предпочтительнее полноразмерного.

Задача 5. Таксономический состав

Уровень классов (Level 3)




Рис. 3. Состав на уровне классов, образцы упорядочены по level_and_time_point.

Группа	Gammaproteobacteria	Acidobacteriae	Alphaproteobacteria	Actinomycetia	Thermoleophila	Bacteroidia
k0_t1	9.7	19.0	16.7	10.5	7.4	5.3
k0_t4	6.4	47.9	16.3	4.8	3.5	2.9
k5_t1	10.4	18.1	16.1	10.8	7.4	5.6
k5_t2	29.7	28.5	11.6	9.7	5.3	0.5
k5_t3	46.5	20.5	11.9	5.8	3.5	0.2
k5_t4	9.0	46.1	11.8	11.7	1.9	0.1
k25_t1	9.3	19.5	17.0	11.2	8.7	4.1
k25_t2	32.3	21.8	13.0	6.1	7.4	0.6
k25_t3	60.6	5.9	8.0	2.9	8.3	0.5
k25_t4	87.5	1.2	3.4	0.9	2.6	0.1

Средняя относительная численность (%) по трём повторностям. Полная таблица по всем группам — в файле soil_L3_group_means.csv.

- **Похожи ли образцы в t1? Да:** в первой точке (3 сут) образцы всех трёх групп очень похожи между собой: и контроль, и оба загрязнённых варианта содержат Acidobacteriae ($\approx 18\text{--}19\%$), Alphaproteobacteria ($\approx 16\text{--}17\%$), Actinomycetia ($\approx 10\text{--}11\%$), Gammaproteobacteria ($\approx 9\text{--}10\%$), Thermoleophila, Planctomycetia и Bacteroidia. За трое суток керосин ещё не успел заметно изменить сообщество;
- **Контроль k0:** состав меняется и без керосина — доля Acidobacteriae растёт с 19 % до $\approx 48\%$ к 360-м суткам, а Actinomycetia и Bacteroidia уменьшаются (эффект долгой инкубации почвы в закрытой ёмкости);
- **Слабое загрязнение k5:** на 90-е и 180-е сутки резко растёт доля Gammaproteobacteria (30 % $\rightarrow$ 47 %), почти исчезают Bacteroidia. К 360-м суткам Gammaproteobacteria снова падают до 9 %, а Acidobacteriae возвращаются к $\approx 46\%$, как в контроле. По составу классов сообщество возвращается к контрольному;

- Сильное загрязнение k25:** Gammaproteobacteria растут на протяжении всего эксперимента (32 → 61 → 87,5 %), а Acidobacteriae, Alphaproteobacteria, Actinomycetia почти исчезают. Через год сообщество практически монодоминантное.

Самые частые классы: в первой точке — Acidobacteriae (≈19 %) и Alphaproteobacteria (≈16–17 %) во всех группах; в последней точке — Acidobacteriae в контроле и k5 (≈46–48 %) и Gammaproteobacteria в k25 (≈88 %).

Уровень родов (Level 6)




Рис. 4. Состав на уровне родов (среднее по трём повторностям каждой группы).

Группа	t1 (3 сут)	t2 (90 сут)	t3 (180 сут)	t4 (360 сут)
k0	0.3 %	0.3 %	0.2 %	0.2 %
k5	0.3 %	15.1 %	24.4 %	5.7 %
k25	0.3 %	26.7 %	50.7 %	83.6 %

Доля рода *Paraburkholderia* (g_ *Paraburkholderia_580243*) по группам.

Самый частый род в загрязнённых образцах — *Paraburkholderia*: до 24 % в k5 (180 сут) и до 84 % в k25 (360 сут), тогда как в контроле его меньше 0,5 %. В k5 на 90–180 сутки также заметен *Nevskia* (6–9 %). В контроле и в k5 на 360-е сутки преобладает ацидобактерия *Acidoferrum* (≈12 % и ≈25 %). В таксономии GTDB/GreenGenes2 бывшие Betaproteobacteria (включая Burkholderiales) отнесены к классу Gammaproteobacteria, поэтому именно рост *Paraburkholderia* даёт «вспышку» Gammaproteobacteria на уровне классов.

Появление *Paraburkholderia* ожидаемо. Представители *Burkholderia*/*Paraburkholderia* — известные деструкторы углеводов: они окисляют алканы и ароматические соединения (в том числе ПАУ), растут на нефти и нефтепродуктах как на единственном источнике углерода и часто доминируют в загрязнённых почвах. Керосин (смесь алканов C9–C16 и ароматических углеводов) становится для них доступным субстратом, поэтому они получают преимущество перед остальным сообществом. Чем больше керосина, тем дольше и сильнее доминирование.

Задача 6. Бета-разнообразие (взвешенный UniFrac, PCoA)




Рис. 5. PCoA по взвешенному UniFrac. Цвет — уровень загрязнения, форма точки — временная точка, линии соединяют центры групп $t1 \rightarrow t2 \rightarrow t3 \rightarrow t4$. Оси объясняют 57,2 %, 22,0 % и 7,8 % вариации.

Группа	t1	t2	t3	t4
k0	0.14	0.08	0.05	0.06
k5	0.12	-0.03	-0.10	-0.00
k25	0.11	-0.04	-0.14	-0.23

Координата центров групп по оси Axis1 (57,2 % вариации).

- **Похожи ли образцы в t1? Да:** в первой временной точке все девять образцов (k0, k5, k25) лежат одним плотным кластером в правой нижней части графика: сообщества практически не различаются.
- **Контроль k0** смещается мало. Небольшой сдвиг по Axis1 и Axis2 отражает естественную динамику при инкубации (рост *Acidobacteria*).
- **k25** непрерывно уходит влево по главной оси Axis1: $t2 \rightarrow t3 \rightarrow t4$ ($-0,04 \rightarrow -0,14 \rightarrow -0,23$). С каждой точкой сообщество всё дальше от контроля, признаков восстановления нет.
- **k5** на 90-е и 180-е сутки уходит влево по Axis1 в ту же сторону, что и k25. Но к 360-м суткам возвращается по Axis1 к нулю, ближе к контролю, и смещается вверх по Axis2 и Axis3. То есть основная «керосиновая» компонента изменений (Axis1, связана с доминированием *Paraburkholderia*) исчезает. Сообщество восстанавливается частично: полного совпадения с контролем нет, остаются отличия по более слабым осям.

PERMANOVA (взвешенный UniFrac, 999 перестановок) подтверждает, что уровень загрязнения значимо влияет на состав (pseudo-F = 7,5, $p = 0,001$). Попарно: k0–k25 $F = 12,8$, $p = 0,001$; k0–k5 $F = 6,3$, $p = 0,003$; k5–k25 $F = 4,3$, $p = 0,014$. По времени значимо отличается только 3-е сутки от остальных точек ($p = 0,001$).

Итог: после слабого загрязнения (5 г/кг) к концу года есть явные признаки восстановления сообщества. После сильного загрязнения (25 г/кг) восстановления за год не происходит, и расхождение с контролем только нарастает.

Задача 7. Альфа-разнообразие (индекс Шеннона)




Рис. 6. Индекс Шеннона и число наблюдаемых ASV (после разрежения до 4800 прочтений). Точки — отдельные образцы, линии — средние по группе.

Группа	d3	d90	d180	d360
k0	8.99 ± 0.04	8.92 ± 0.02	8.64 ± 0.04	8.27 ± 0.12
k5	9.07 ± 0.11	7.75 ± 0.05	6.59 ± 0.23	6.79 ± 0.11
k25	8.93 ± 0.06	7.61 ± 0.16	5.87 ± 0.42	2.93 ± 0.32

Индекс Шеннона, среднее ± SD (n = 3).

- в первой точке разнообразие во всех группах одинаково высокое ($H \approx 9$);
- в контроле (k0) разнообразие за год снижается незначительно ($9,0 \rightarrow 8,3$) из-за изменений при инкубации;
- при слабом загрязнении (k5) индекс Шеннона падает к 180-м суткам ($\approx 6,6$), а к 360-м стабилизируется и чуть растёт ($\approx 6,8$), когда уходит доминирование *Paraburkholderia*. Разнообразие не вернулось к уровню контроля, но падение остановилось;
- при сильном загрязнении (k25) разнообразие непрерывно падает до $H \approx 2,9$ на 360-е сутки, а число ASV снижается с ≈ 760 до ≈ 200 . Это отражает почти монодоминантное сообщество с *Paraburkholderia* ($\approx 84\%$).

Тест Краскела–Уоллиса по группам level_and_time_point: $H = 34,1$, $p = 3,5 \cdot 10^{-4}$; по уровню загрязнения: $H = 9,9$, $p = 0,007$; по времени: $H = 21,7$, $p = 7,5 \cdot 10^{-5}$. Число наблюдаемых ASV меняется так же (по уровню загрязнения $p = 0,024$); филогенетическое разнообразие Фейта значительно снижается со временем ($p = 5 \cdot 10^{-6}$), но по уровню загрязнения в целом не различается ($p = 0,21$). Попарные сравнения при $n = 3$ в группе имеют низкую мощность, поэтому основные выводы сделаны по общей картине.

Общий вывод по почве: загрязнение керосином в первые дни не меняет сообщество, но затем приводит к росту углеводород-окисляющих *Paraburkholderia* и снижению разнообразия. При 5 г/кг сообщество за год в значительной мере восстанавливается, при 25 г/кг — нет: к концу года оно почти монодоминантно.

Часть 2. Данные семинара (mice)

29 образцов в 4 группах: W (7), WR (7), L (8), LR (7). Парноконцевые прочтения 2×250 нт, регион V4 (515F–806R), праймеры уже удалены (прочтения начинаются с TACG...). Выполнен тот же конвейер QIIME 2, что и для почвы, но с парными прочтениями.

Контроль качества




Рис. 7. FastQC, образец L1, обратные прочтения R2: качество резко падает после ~160–200 нт.

Образец L1: 3 773 пары прочтений длиной 250 нт, GC ≈ 52–53 %. Прямые прочтения имеют хорошее качество почти по всей длине, в обратных после ~160 нт качество быстро падает (медиана к концу опускается ниже Q20). Поэтому при DADA2 R1 обрезались до 230 нт, R2 — до 200 нт. Суммарная длина 430 нт с запасом перекрывает ампликон V4 (~253 нт), и пары успешно склеиваются.

Фильтрация (DADA2 denoise-paired)

Показатель	Значение
Прошло фильтр по качеству	78,6 % (в среднем)
Успешно склеено пар	67,9 %
Осталось после удаления химер	66,9 % (55–75 % по образцам)
Самый маленький образец	W1 — 1 314 прочтений
Самый большой образец	LR2 — 4 778 прочтений
Глубина разрежения (sampling depth)	1 314 (все 29 образцов сохранены)

Потери больше, чем у почвы, из-за низкого качества концов R2 и потерь при склейке. Для этого семинарского набора (небольшое число прочтений на образец) результат приемлемый.

Таксономический состав




Рис. 8. Mice: состав на уровне классов.

Класс	W	WR	L	LR
Clostridia	33.4	58.0	74.4	83.1
Bacteroidia	24.1	21.8	13.8	10.8
Campylobacteria (Helicobacter)	22.7	11.5	0.0	0.0
Desulfovibrionia	7.9	3.6	0.0	0.0
Deferribacteres (Mucispirillum)	0.5	2.8	6.5	3.0
Bacilli	4.9	1.0	3.1	1.9

Средняя относительная численность, %. Для классификации использован классификатор GreenGenes2 2022.10 V4: лежащий в папке семинара gg-13-8-99-515-806 обучен в старой версии scikit-learn (0.24) и несовместим с QIIME 2 2024.10.

Во всех группах преобладают Clostridia и Bacteroidia, типичные для кишечника мыши. Группы W и WR отличаются от L и LR наличием Campylobacteria (род Helicobacter, 11–23 %) и Desulfovibrionia (Mailhella). В группах L и LR этих классов нет, а доля Clostridia значительно выше (74–83 %); в L также заметен Mucispirillum (Deferribacteres).

Разнообразие




Рис. 9. Мисе: PCoA по взвешенному UniFrac (слева) и индекс Шеннона по группам (справа).

Группа	Индекс Шеннона	Число ASV
W	4.68 ± 0.38	55 ± 12
WR	5.66 ± 0.28	92 ± 10
L	5.18 ± 0.18	62 ± 10
LR	5.71 ± 0.18	88 ± 7

Альфа-разнообразие значительно различается между группами (Краскел-Уоллис: Шеннон $H = 20,7$, $p = 1,2 \cdot 10^{-4}$; число ASV $H = 21,4$, $p = 8,6 \cdot 10^{-5}$). Самое низкое разнообразие в группе W, самое высокое — в WR и LR.

На PCoA (взвешенный UniFrac) первая ось (60,1 %) отделяет группы W/WR от L/LR, вторая ось (15,2 %) отделяет WR от W. Группы L и LR лежат близко друг к другу. PERMANOVA: pseudo-F = 18,3, $p = 0,001$; все попарные различия значимы ($p \leq 0,002$), наименьшее различие между L и LR ($F = 5,2$), наибольшее между L и WR ($F = 34,9$). Аналогичный результат дают невзвешенный UniFrac ($F = 10,8$) и Брея-Кёртиса ($F = 11,7$).